

ANÁLISIS DE DATOS MASIVOS

LEARNING TO RANK

Blanca Vázquez

4 de noviembre de 2024

- En la práctica, los sistemas de recomendación solo muestran al usuario los elementos como una lista ordenada
- Los usuarios usualmente le ponen atención a los primeros elementos de la lista
- Los modelos basados en predecir la calificación no consideran explícitamente el ordenamiento
 - Usualmente primero se realiza la predicción de la calificación de cada elemento y posteriormente se ordena a partir de esta calificación

- En *learning to rank*, se aplica aprendizaje supervisado para realizar el ordenamiento de un conjunto de elementos
- Tipos
 - A nivel elemento: cada elemento se clasifica como relevante o no relevante
 - A nivel par: predice el orden relativo de cada par de elementos
 - A nivel lista: genera el orden de una lista completa

- Se basa en los atributos de cada elemento de forma individual
- Datos de entrenamiento: elementos y su calificación (e.g. relevante/no relevante o valor numérico)
- Ejemplos: Pranking o McRank

- Aprende un modelo h que determina el orden relativo de dos elementos $(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$, es decir, si $\mathbf{x}^{(i)}$ va antes o después que $\mathbf{x}^{(j)}$
- Datos de entrenamiento: pares de elementos y cuál es más relevante
- Ejemplo: RankNet, LambdaRank o RankingSVM

- Optimiza una función de pérdida basada en el ordenamiento completo de una lista
 - Ejemplos de funciones de pérdida: *normalized cumulative discounted gain (NDCG)* y *mean reciprocal rank (MRR)*
- Problema: hay muchos posibles ordenamientos de una misma lista
- Ejemplos: ListNet, ListMLE o PermuRank

LEARNING TO RANK Y RECUPERACIÓN DE INFORMACIÓN

- Aplicado a motores de búsqueda donde hay un conjunto de consultas Q , cada uno con su correspondiente conjunto de respuesta S y el problema es ordenar S

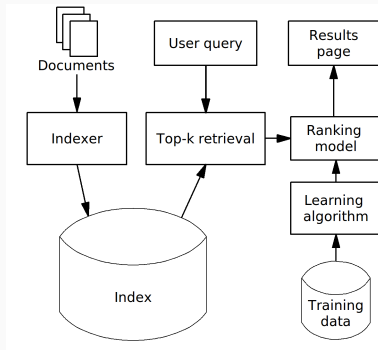


Imagen del dominio público, creada por el usuario X7q de Wikipedia.

- Método de *learning to rank* en el que se entrena un modelo optimizando una función diferenciable respecto a sus parámetros
 - Usualmente una red neuronal, aunque también se han usado árboles de potenciación del gradiente
 - Cada ejemplo $\mathbf{x}^{(i)}$ se mapea a un número $h(\mathbf{x}^{(i)})$
- Por ej. red neuronal tipo siamesa entrenada para aprender el orden relativo de dos elementos

- Busca aprender el orden relativo de dos elementos
- Para una consulta, se elige un par de ejemplos $(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$ con etiquetas diferentes y se calcula

$$s^{(i)} = h(\mathbf{x}^{(i)})$$

$$s^{(j)} = h(\mathbf{x}^{(j)})$$

- Estas salidas se mapean a una probabilidad de que $\mathbf{x}^{(i)}$ es más relevante que $\mathbf{x}^{(j)}$

$$P_{i,j} \equiv \frac{1}{1 + e^{-\sigma(s^{(i)} - s^{(j)})}}$$

donde σ es un parámetro que determina la forma de la función sigmoide

- Se busca minimizar la entropía cruzada binaria

- Es similar a RankNet pero en el entrenamiento se busca maximizar el *Normalized Discounted Cumulative Gain* (NDCG)

$$NDCG@T = \frac{DCG@T}{\text{máx}(DCG@T)} \in [0, 1]$$

$$DCG@T = \sum_{i=1}^T \frac{2^{y^{(i)}} - 1}{\log(1 + i)}$$

donde T es el nivel de truncamiento, $y^{(i)}$ es la etiqueta asociada al i -ésimo elemento de la lista

- Se especifican los gradientes directamente, en lugar de derivarlos